

AMN vs. Apandisit 3D CT Sınıflandırma

Q1 Benchmark Raporu

experiments_q1_128 | External Test: n=24 | @Youden Threshold

Oluşturulma: 2026-07-28

1. Dataset Özeti

Toplam hasta: 143 (117 Müsinöz AMN, 26 Apandisit) — Tek merkez, retrospektif.
Veri bölme: StratifiedGroupKFold (hasta bazlı, leakage yok).

Bölüm	Müsinöz (AMN)	Apandisit	Toplam	Oran
Train+Val (5-fold)	98	21	119	4.7:1
External Test (holdout)	19	5	24	3.8:1
TOPLAM	117	26	143	4.5:1

Fold	Train (M/A)	Val (M/A)
Fold 1	78 / 18 = 96	20 / 4 = 24
Fold 2	78 / 18 = 96	20 / 4 = 24
Fold 3	79 / 18 = 97	19 / 4 = 23
Fold 4	78 / 17 = 95	20 / 5 = 25
Fold 5	79 / 17 = 96	19 / 5 = 24

2. Ensemble @Youden — External Test Master Tablosu (n=24)


Model	AUC	95% CI	SENS	SPEC	PPV	NPV	F1	ACC	Brier	ECE
SwinUNETR Linear-Probe	0.853	[0.674-0.979]	0.789	1.000	1.000	0.556	0.882	0.833	0.138	0.174
SegFormer3D-MSCA	0.821	[0.591-0.989]	0.789	0.800	0.937	0.500	0.857	0.792	0.152	0.173
Attention-SwinUNETR	0.821	[0.624-0.968]	0.842	0.800	0.941	0.571	0.889	0.833	0.133	0.079
MAE-TinyTransformer3D	0.800	[0.589-0.958]	0.632	1.000	1.000	0.417	0.774	0.708	0.134	0.109

2.1 DeLong Pairwise AUC Karşılaştırması

Model 1	AUC1	Model 2	AUC2	Δ AUC	z	p-value	p<0.05?
Attention-SwinUNETR	0.821	MAE-TinyTransformer3D	0.800	+0.021	0.281	0.7787	✗
Attention-SwinUNETR	0.821	SegFormer3D-MSCA	0.821	+0.000	0.000	1.0000	✗
Attention-SwinUNETR	0.821	SwinUNETR Linear-Probe	0.853	-0.032	-0.744	0.4571	✗
MAE-TinyTransformer3D	0.800	SegFormer3D-MSCA	0.821	-0.021	-0.261	0.7944	✗
MAE-TinyTransformer3D	0.800	SwinUNETR Linear-Probe	0.853	-0.053	-0.584	0.5592	✗
SegFormer3D-MSCA	0.821	SwinUNETR Linear-Probe	0.853	-0.032	-0.298	0.7658	✗


3. Grafikler

3.1 AUC-ROC Karşılaştırması (95% Bootstrap CI)




Şekil 1. Ensemble @Youden external test AUC-ROC. Kırmızı kesikli çizgi Q1 hedef eşiği (0.80).

3.2 Sensitivity vs Specificity




Şekil 2. Klinik kısıtlar: SENS $\geq$ 0.80 (kırmızı), SPEC $\geq$ 0.50 (gri).

3.3 ROC Eğrileri (Ensemble Olasılıkları)




Şekil 3. Tüm modellerin ROC eğrileri, ensemble posterior probability ile.

3.4 Fold-Bazlı AUC-ROC



Şekil 4. Her fold için external test AUC-ROC. Fold 5 tüm modellerde düşük.

3.5 Fold-Bazlı F1-Score



Şekil 5. F1-Score fold dağılımı.

4. Model Bazlı Fold Metrikleri

Attention-SwinUNETR (AG-MSF)

Fold	AUC	SENS	SPEC	F1	ACC	TP	FP	FN	TN
Fold 1	0.853	0.789	1.000	0.882	0.833	15	0	4	5
Fold 2	0.800	0.737	1.000	0.848	0.792	14	0	5	5
Fold 3	0.811	0.632	1.000	0.774	0.708	12	0	7	5
Fold 4	0.821	0.842	0.800	0.889	0.833	16	1	3	4
Fold 5	0.789	0.579	1.000	0.733	0.667	11	0	8	5
Ensemble	0.821	0.842	0.800	0.889	0.833	—	—	—	—

MAE-TinyTransformer3D

Fold	AUC	SENS	SPEC	F1	ACC	TP	FP	FN	TN
Fold 1	0.800	0.737	1.000	0.848	0.792	14	0	5	5
Fold 2	0.747	0.579	1.000	0.733	0.667	11	0	8	5
Fold 3	0.695	0.526	1.000	0.690	0.625	10	0	9	5
Fold 4	0.832	0.842	0.800	0.889	0.833	16	1	3	4
Fold 5	0.905	0.737	1.000	0.848	0.792	14	0	5	5
Ensemble	0.800	0.632	1.000	0.774	0.708	—	—	—	—

SegFormer3D-MSCA

Fold	AUC	SENS	SPEC	F1	ACC	TP	FP	FN	TN
Fold 1	0.874	0.789	1.000	0.882	0.833	15	0	4	5
Fold 2	0.758	0.737	0.800	0.824	0.750	14	1	5	4
Fold 3	0.674	0.895	0.600	0.895	0.833	17	2	2	3
Fold 4	0.653	0.895	0.600	0.895	0.833	17	2	2	3
Fold 5	0.874	0.789	1.000	0.882	0.833	15	0	4	5
Ensemble	0.821	0.789	0.800	0.857	0.792	—	—	—	—

SwinUNETR Linear-Probe

Fold	AUC	SENS	SPEC	F1	ACC	TP	FP	FN	TN
Fold 1	0.832	0.684	1.000	0.812	0.750	13	0	6	5
Fold 2	0.884	0.789	1.000	0.882	0.833	15	0	4	5
Fold 3	0.842	0.789	1.000	0.882	0.833	15	0	4	5
Fold 4	0.895	0.789	1.000	0.882	0.833	15	0	4	5
Fold 5	0.674	0.579	1.000	0.733	0.667	11	0	8	5

Ensemble	0.853	0.789	1.000	0.882	0.833	—	—	—	—
-----------------	--------------	--------------	--------------	--------------	--------------	----------	----------	----------	----------

5. Metodoloji Özeti

5.1 Sınıf Dengesizliği Stratejisi

- Clinical Focal Loss: $\text{pos_weight}=3.0$ ($q1_final$), $\gamma=1.5$, $\text{label smoothing}=0.10$
- Threshold: Çift kısıt ($\text{SENS} \geq 0.80$ VE $\text{SPEC} \geq 0.50$) → F1 maksimize → Youden fallback
- Bootstrap CI: $n=2000$, %95 güven aralığı

5.2 Eğitim Protokolü (Tüm DL Modeller)

- Optimizer: AdamW | LR: $1e-4$ – $5e-4$ | Weight Decay: $1e-2$
- Scheduler: Linear Warmup (10 epoch) + Cosine Annealing
- SWA: Son %30 epoch ($\text{epoch} \geq 70$), $\text{swa_lr} = \text{base_lr} \times 0.1$
- Gradient Accumulation: $\text{accum_steps}=4-8$ → $\text{eff. batch}=16$
- EMA checkpoint seçimi: $\alpha=0.3$
- TTA: 4 yön (original + D/H/W flip), olasılık ortalaması

5.3 Validasyon Protokolü

- 5-Fold StratifiedGroupKFold (hasta bazlı, leakage yok)
- Bağımsız external holdout: $n=24$ (bu rapor) / $n=37$ ($q1_final$)
- DeLong pairwise AUC testi (Sun & Xu, 2014)
- Kalibrasyon: Brier score + ECE (10 bin)

5.4 Model Seçim Gerekçesi

- SwinUNETR Linear-Probe: Frozen pretrained backbone → overfitting riski minimal
- Attention-SwinUNETR: 5-stage hierarchical multi-scale fusion (AG-MSF, özgün)
- MAE-TinyTransformer3D: Self-supervised pretraining (özgün 3D MAE adaptasyonu)
- SegFormer3D-MSCA: 3D SegFormer + CBAM + multi-scale fusion (özgün)
- Radiomics baselines: Klasik el-yapımı öznitelik karşılaştırması

6. Temel Bulgular

1. SwinUNETR Linear-Probe en yüksek AUC'yi elde etti (0.853, 95%CI [0.674-0.979]), SPEC=1.000 ile hiçbir Apandisit vakasını AMN olarak yanlış sınıflandırmadı.
2. Attention-SwinUNETR en yüksek SENS'i sağladı (0.842), klinik açıdan en kritik metrikte (FN minimizasyonu) öne çıktı.
3. DeLong testi hiçbir model çifti için $p < 0.05$ sonuç vermedi — küçük external test seti ($n=24$) istatistiksel güç sınırlıdır.
4. Fold 5 tüm modellerde zayıf ($SENS \approx 0.58$, $FN=8$) — bu fold'daki hasta dağılımı incelenmeli.
5. MAE pretraining (TinyTransformer3D) en yüksek SPEC'i (1.000) verdi ancak $SENS=0.632$ ile AMN vakalarının %37'sini kaçırdı.

Limitasyonlar

- Tek merkez, retrospektif, $n=143$ (küçük kohort)
- Ciddi sınıf dengesizliği (4.5:1) — AMN nadir tümör
- External test $n=24$; DeLong testi için yetersiz istatistiksel güç
- Radiomics baseline bu raporda mevcut değil (henüz koşturulmadı)